Apache Kafka

Requisitos

- Docker instalado na máquina

Objetivo

O objetivo deste tutorial é trazer conceitos importantes acerca de kafka, e uma demonstração simples da sua utilização.

O que é Apache kafka?

O Apache Kafka é uma plataforma de software de código fonte aberto para processamento de fluxo de mensagens escrita em Scala com Java. Kafka foi criado como uma solução interna de infra-estrutura na LinkedIn para lidar com os dados como um fluxo contínuo e crescente de informação para aplicações.

Um cluster Kafka é não só altamente escalável e tolerante a falhas, mas ele também tem uma taxa de transferência muito mais alta comparada com outros message brokers. O Kafka funciona como um **cluster de brokers** e isso permite configurações interessantes de disponibilidade, o que atrai a grandes empresas com sistemas críticos.

Apache Kafka Broker

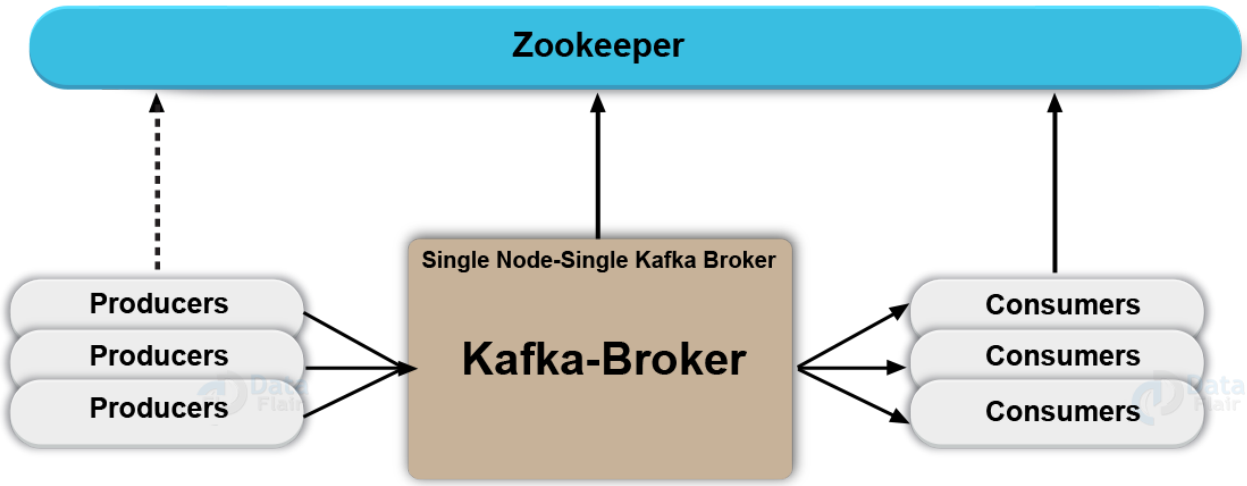

O Zookeeper é um serviço centralizado para, entre outras coisas, coordenação de sistemas distribuídos. O Kafka é um sistema distribuído, e consequentemente delega diversas funções de gerenciamento e coordenação para o Zookeeper. Segundo a Confluent(empresa responsável por aprimorar e adicionar recursos ao Kafka) afirma que dentro algumas releases, a dependência do kafka com zookeeper será completamente removida

Broker e Cluster

O conceito de broker na plataforma do Kafka é nada mais do que praticamente o proprio Kafka, ele é quem gerencia os tópicos, define a forma de armazenamento das mensagens, logs etc.

O conceito de cluster é nada mais do que um conjunto de Brokers que se comunicam entre si ou não para uma melhor escalabilidade e tolerância a falhas.

Mensagens

Entenda por mensagens toda a informação que trafega sobre o Apache Kafka, seja uma frase, uma palavra, um array de bytes etc..

Tópicos

Um tópico é uma forma de rotular ou categorizar uma mensagem, imagine um armário com 10 gavetas, cada gaveta pode ser um tópico e o armário é a plataforma Apache Kafka, portanto alem de categorizar ele agrupa as mensagens

Partições

As partições é a camada de partição das mensagens dentro de um tópico, este particionamento garante a elasticidade, tolerância a falha e escalabilidade do Apache Kafka, portanto cada tópico pode ter varias partições em diferentes localidades.

Producer

O Kafka utiliza o conceito de produtores e consumidores para definir os clientes que se conectam ao broker. Produtores criam as mensagens para um tópico específico, isso não é regra e sim o comportamento mais comum. O produtor no geral não se preocupa em qual partição a mensagem será salva e faz o balanceamento entre todas as disponíveis.

Consumer

Consumidores leem as mensagens produzidas e controlam o consumo através dos offsets das mensagens. O offset da última mensagem é armazenado e com isso o consumidor pode parar e iniciar sem perder o histórico.

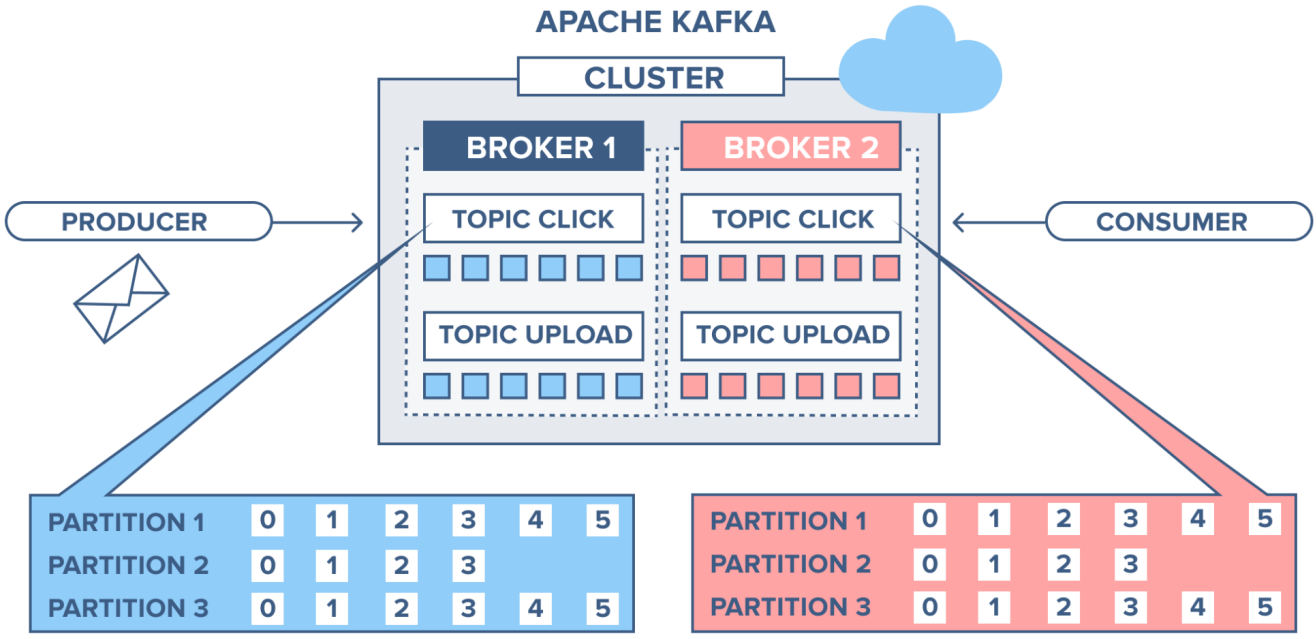

Hands on

Iniciando os serviços

Para iniciar o nosso tutorial prático, utilizaremos Docker.

Primeiro iremos iniciar nossos containers,zookeeper, borker kafka e kafdrop(ferramenta que irá fornecer uma UI amigável para realizarmos nossos testes) Faça download da imagem do Redis:

```
$ docker-compose up -d
```

Com o comando `docker network ls` podemos confirmar que a rede kafka-tutorial_broker-kafka foi criada com sucesso. Já o comando `docker-compose ps` mostrará que os containers dos serviços subiram. Lembrando que para acessar a Ui do kafkdrop acesse o http://localhost:19000 .

Criando um Tópico

Vamos começar a usando command line do kafka, como o comando a seguir sugere criaremos um topico com nome de "my_first_topic"

```
$ docker exec broker \
kafka-topics --bootstrap-server broker:9092 \
             --create \
             --topic my_first_topic
```

Produzindo algumas mensagens

Nós podemos usar o command line do kafka-console-producer para gerar mensagens em um tópico. Isso é útil para esse tutorial, mas na prática usaremos a API do Producer no código do aplicativo ou o Kafka Connect para extrair dados de outros sistemas para o Kafka.

```
$ docker exec --interactive --tty broker \
kafka-console-producer --bootstrap-server broker:9092 \
                       --topic quickstart
```

Lendo algumas mensagens

Agora que escrevemos a mensagem para o tópico, vamos ler essas mensagens de volta. Execute este comando para iniciar o kafka-console-consumer. **O `--from-beginning` é um argumento para que as mensagens sejam lidas desde o início do tópico.

```
$ docker exec --interactive --tty broker \
kafka-console-consumer --bootstrap-server broker:9092 \
                     --topic quickstart \
                     --from-beginning
```

Brincando um pouquinho com o Kafka

Agora iremos explorar um pouquinho mais a teoria explicada acima. Primeiro criaremos um outro tópico com 3 partições.

```
$ docker exec broker \
kafka-topics --bootstrap-server broker:9092 \
             --create \
             --partitions 3 \
             --replication-factor 1 \
             --topic new_topic
```

Em seguida, abra outro terminal e criaremos um consumidor e o colocaremos em um consumer group

```
$ docker exec broker \
kafka-console-consumer --bootstrap-server broker:9092 \
           --topic new_topic \
           --group microservice-1
```

Replique essa etapa para outros dois terminais. Após isso comece a produzir mensagens para este topico

```
$ docker exec --interactive --tty broker \
kafka-console-producer --bootstrap-server broker:9092 \
                     --topic new_topic
```

Iremos perceber que cada membro do consumer group está lendo de uma partição específica. Podemos ir além e subir um 4º membro para esse grupo e perceberemos também que ele ficará ocioso, pois cada membro só pode ler uma partição do tópico.

Conclusão

Depois de tudo que foi dito concluimos que o **Kafka** é um sistema de mensageria que traz a proposta de unir o melhor dos modelos tradicionais de fila e publish-subscribe, permitindo a escalabilidade do processamento de mensagens do primeiro e a distribuição em massa das mensagens do segundo. Vale ressaltar que o kafka é uma ferramenta muito poderosa e não é indicado para aplicações simples, pois existe uma curva de aprendizado considerável e uma complexidade nas configurações.